Analyse lexicale

Dr. Aida Lahouij
Maitre assistante de l’enseignement supérieur et de la recherchce scientifique
Aida.lahouij@gmail.com

CONTENTS

01 Introduction

02 Analyse Lexicale automatique

03 Analyse Lexicale Manuelle

04 Conclusion

Introduction:

Qu'est-ce que l'analyse lexicale ?

- Première phase de la compilation.
- Transformation du code source en une suite de lexèmes (unités significatives).
- Objectif : Générer des tokens (symboles) pour l'analyse syntaxique.

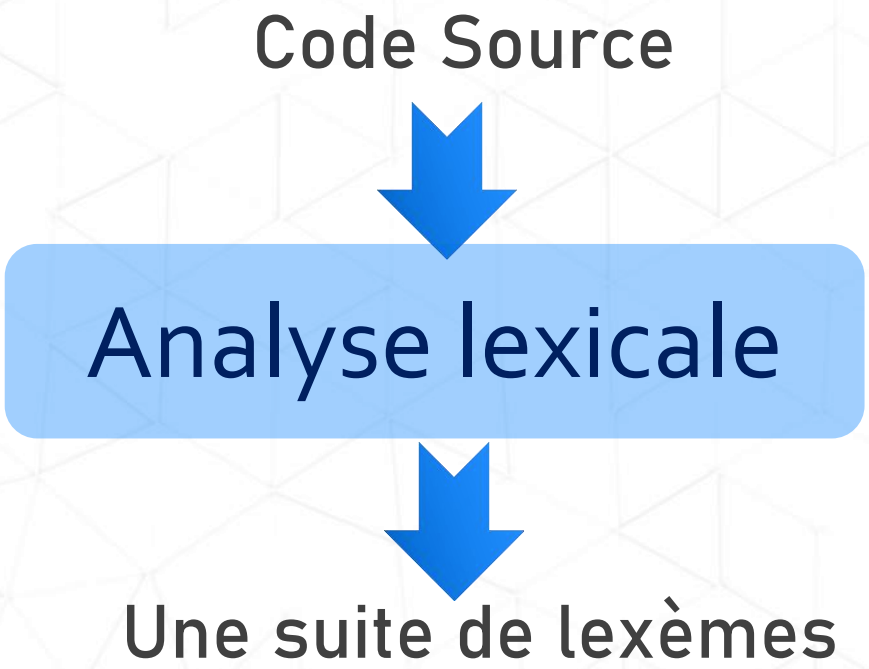

Introduction:

Exemple :

- Code : `x = 42 + y;`

→ Tokens :
[IDENT, x],
[ASSIGN, =],
[NUMBER, 42],
[OP, +],
[IDENT, y],
[SEMICOLON, ;]

Introduction:

Composants clés

Token : Symbole catégorisé (ex: IF, NUMBER, IDENT).

Lexème : Séquence de caractères correspondant à un token.

Motifs (patterns) : Règles regex pour identifier les lexèmes.

Introduction:

Remarque

L'analyseur lexical ne traite en général pas les combinaisons d'unités lexicales, cette tâche étant laissée à l'analyseur syntaxique.

Exemple:

- un analyseur lexical typique peut reconnaître et traiter les parenthèses mais est incapable de les compter et donc de vérifier si chaque parenthèse fermante «) » correspond à une parenthèse ouvrante « (» précédente.

Introduction:

Remarque

On distingue deux types d'analyse lexicale:

- **l'analyse lexicale automatique**
  - par un générateur d'analyseurs lexicaux : Lex, Flex., ANTLR, etc.
- **l'analyse lexicale manuelle** (codée à la main)
  - « à la main » : il faut construire l'automate fini non déterministe à partir d'une expression rationnelle E, puis l'exécuter pour déterminer si une chaîne d'entrée appartient au langage reconnu par E ;
  - par **une table** décrivant l'automate et un programme exploitant cette table ;

01

Analyse lexicale automatique

L'analyse lexicale automatique:

Outils et technologies

Lex (outil UNIX pour générer des analyseurs lexicaux).

Flex (version open source de Lex).

Expressions régulières (définir les motifs des tokens).

ANTLR (générateur d'analyseurs syntaxiques et lexicaux).

L'analyse lexicale automatique:

Flex (Fast Lexical Analyzer Generator)

Qu'est-ce que Flex ?

- Outil open source pour générer des analyseurs lexicaux (lexers).
- Transforme des règles regex en code C optimisé.

Pourquoi Flex ?

- Rapide, léger, compatible avec Bison (analyse syntaxique).
- Idéal pour les compilateurs, interprètes, ou outils de traitement de te

L'analyse lexicale automatique:

Flex

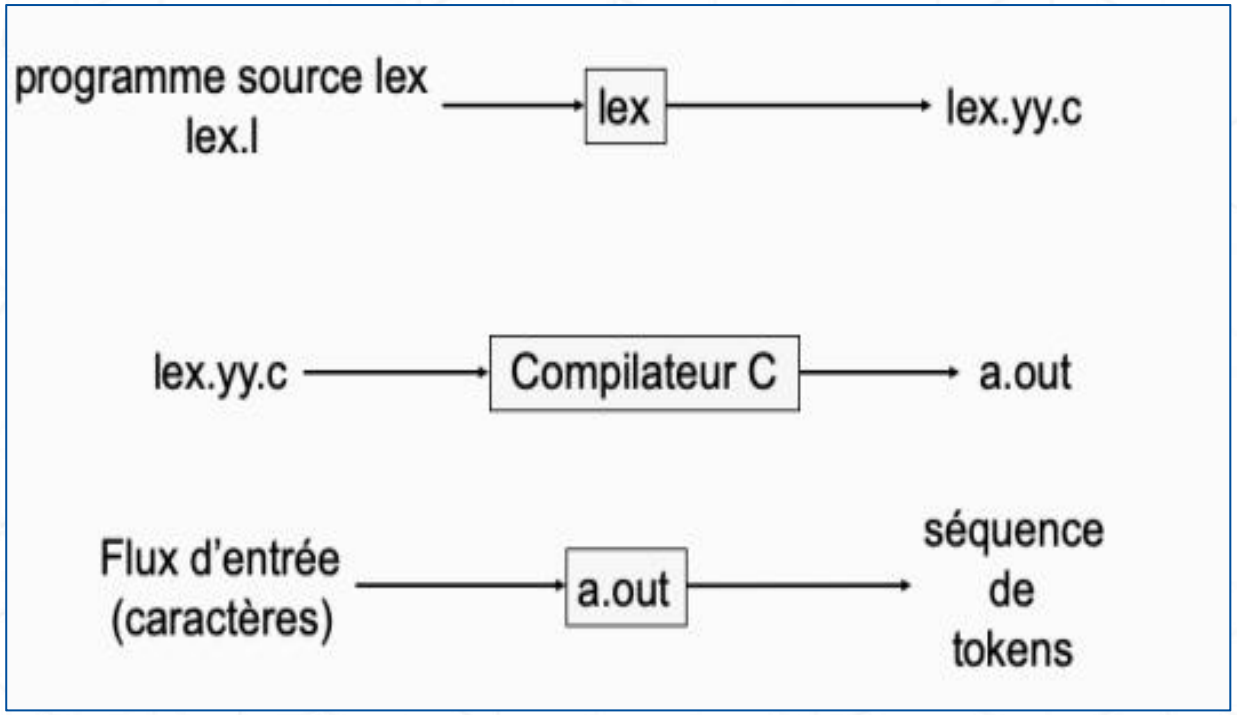

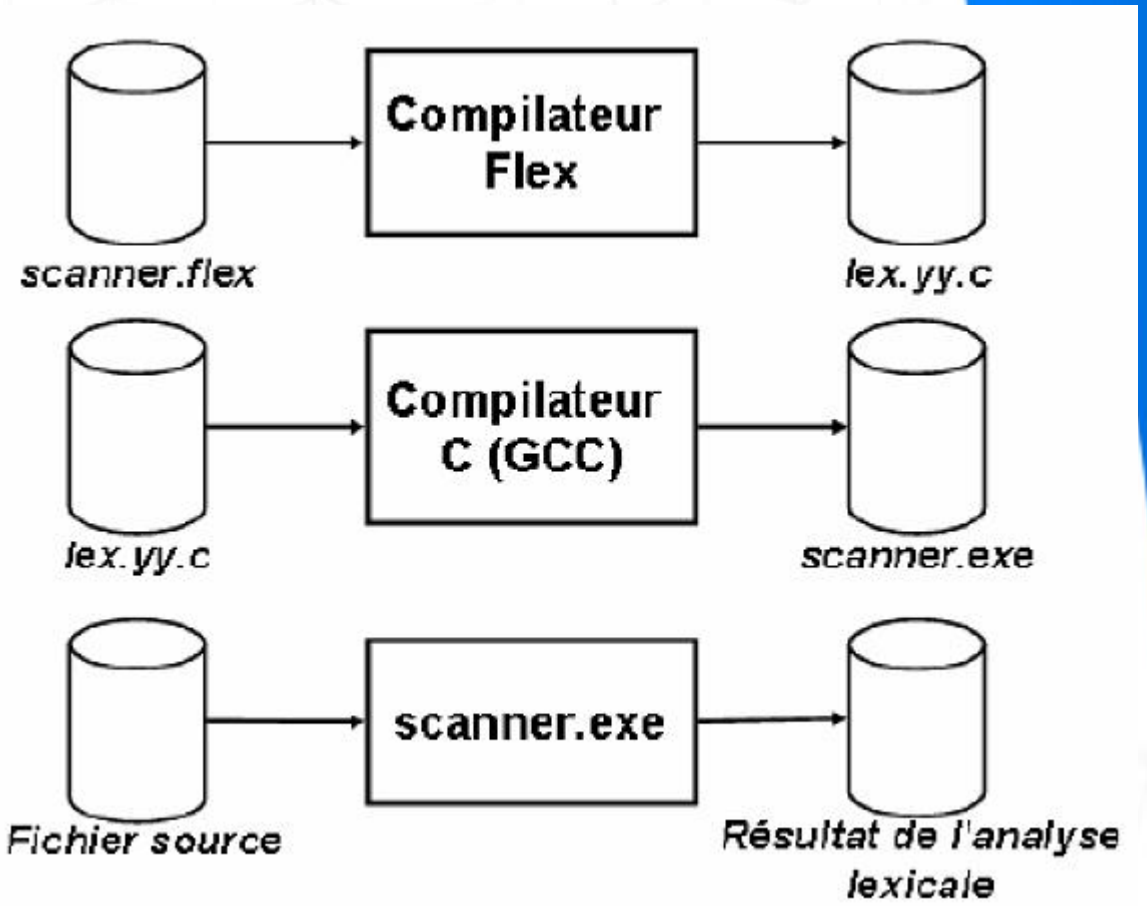

01

Analyse lexicale automatique

Programme source lex (Fichier .l ou .lex)

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

- C'est le fichier source contenant les règles lexicales écrites en syntaxe Flex/Lex.
- Définit les motifs (regex) et les actions associées (code C).

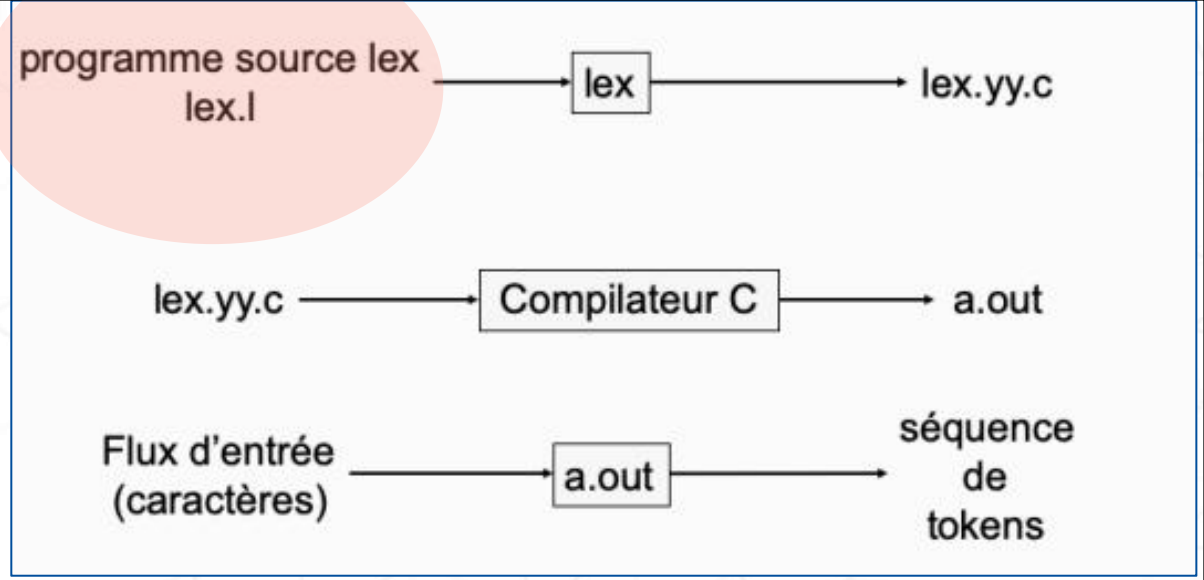


```
%{
#include <stdio.h>
%}
%%
[0-9]+   { printf("Nombre: %s\n", yytext); }
[a-zA-Z]+ { printf("Mot: %s\n", yytext); }
%%
int main()
{ yylex();
return 0; }
```

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

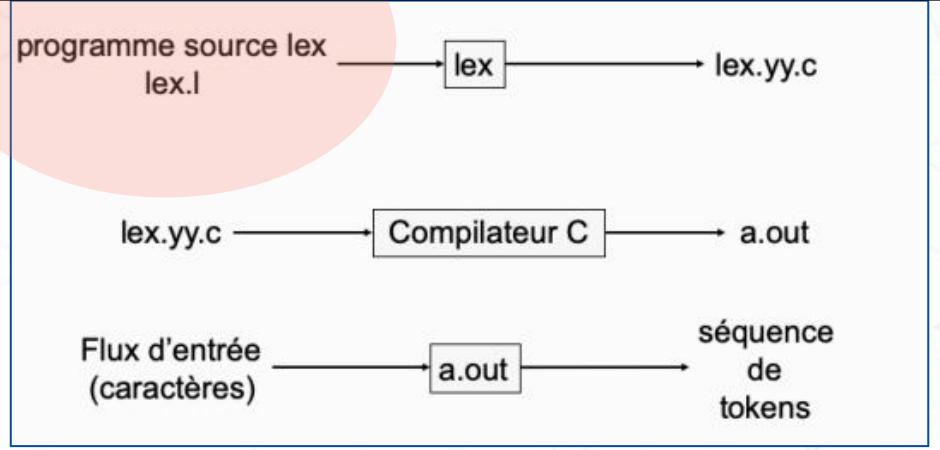

Le contenu d'un fichier Flex comprend 3 sections séparées par une ligne contenant le symbole « %% » :

```
%{
 /*   Déclarations *  /
%}
/*   Définitions *  /
 %%
 /*   Règles et actions
*  /
 %%
 /*   Code utilisateur *  /
```

1.Déclarations (%{ … %}) : Code C (en-têtes, variables).

2.Règles Lexicales (%% … %%) : Regex + Actions.

3.Code Utilisateur : Fonctions supplémentaires (ex: main()).

Exemple Minimal :

```
lex

%{
#include <stdio.h>
%}
%%
.   { printf("Caractère: %s\n", yytext); }
%%
int main() { yylex(); return 0; }
```

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

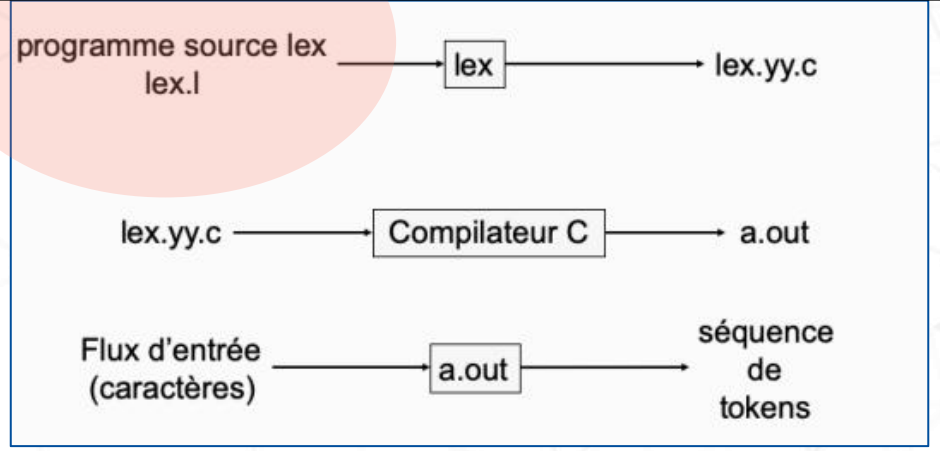

/* Déclarations * /

- Contient la déclaration des variables et des fonctions globales, des inclusions de fichiers.

- Les inclusions de fichiers et les déclarations des variables et des fonctions globales sont mises entre les symboles « %{ » et « %} », chacun sur une seule ligne qui ne doit pas être indentée).

Exemple :

```
%{
#include<stdio.h>
#define N 100
int x = 12;
float z = 1.5; // une variable globale
int fct(int, float); // une fonction globale
%}
```

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

/* Définitions * /

- Une définition permet de nommer une expression régulière.
- Une définition est un couple formé d'un identificateur et d'une expression régulière, séparée par au moins un caractère espace (ou tabulation).
- Une expression régulière peut contenir une référence à un identificateur déjà défini.
- Dans ce cas, l'identificateur doit être écrit entre les symboles "{" et "}".
- Une définition doit être écrite sur une seule ligne.

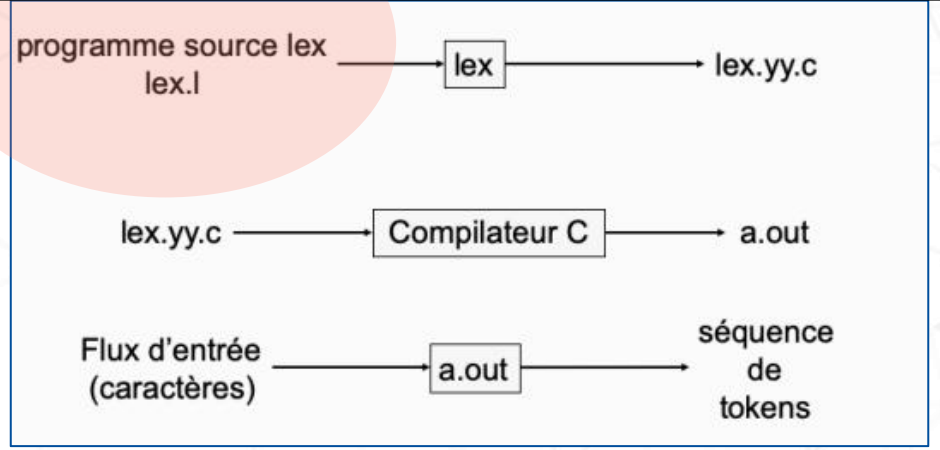

Exemple :

CHIFFRE [0 – 9]

ENTIER (+|–)? {CHIFFRE} +

Syntaxe :

Nom Expression_Régulière

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

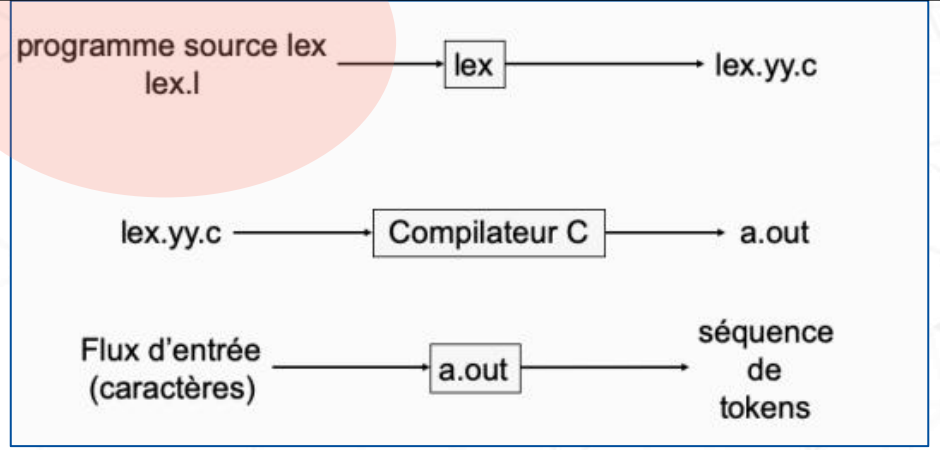

/* Règles * /

- Une règle Flex est la donnée :
  - d'une expression régulière.
  - et d'une action (celle qui sera exécutée lorsqu'une séquence d'entrée est reconnue).
- Les règles de traduction sont de la forme

  p1 { action1 }
  p2 { action2 }
  ...
  pn { actionn }

où chaque pi est une expression rationnelle et chaque action est une suite d'instructions en C.

Exemple :

"int" {printf ("Mot cle int"); }

A chaque fois que la chaîne de caractères "int" sera reconnue, le message "Mot cle int" sera affiché sur la sortie standard.

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

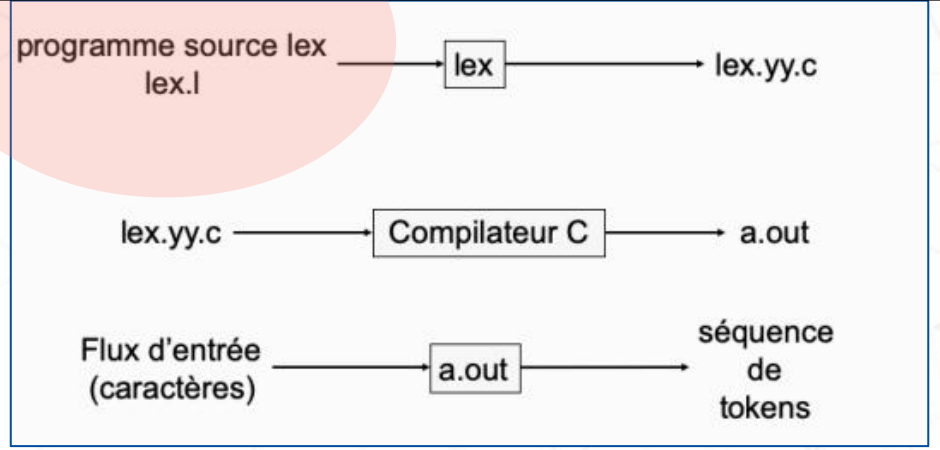

Motif (Pattern)	Correspondances possibles
`[0-9]`	Tous les chiffres entre `0` et `9`.
`[0+9]`	Soit `0`, `+` ou `9`.
`[0, 9]`	Soit `0`, `,`, `' '` (espace) ou `9`.
`[0 9]`	Soit `0`, `' '` (espace) ou `9`.
`[-09]`	Soit `-`, `0` ou `9`.
`[-0-9]`	Soit `-`, ou tous les chiffres entre `0` et `9`.
`[0-9]+`	Un ou plusieurs chiffres entre `0` et `9`.
`[^a]`	Tous les caractères sauf `a`.
`[^A-Z]`	Tous les caractères sauf les lettres majuscules (`A-Z`).

`a{2,4}`	`aa`, `aaa` ou `aaaa`.
`a{2,}`	Deux occurrences ou plus de `a`.
`a{4}`	Exactement 4 occurrences de `a`, soit `aaaa`.
`.`	N'importe quel caractère sauf une nouvelle ligne (`\n`).
`a*`	Zéro ou plusieurs occurrences de `a`.
`a+`	Une ou plusieurs occurrences de `a`.
`[a-z]`	Toutes les lettres minuscules (`a` à `z`).
`[a-zA-Z]`	Toute lettre alphabétique (`a-z` ou `A-Z`).
`w(x|y)z`	`wxz` ou `wyz`

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

/* Code Utilisateur* /

- La fonction main() pour exécuter l'analyseur lexical.
- Des fonctions auxiliaires (ex: affichage, calculs).
- Des initialisations personnalisées.

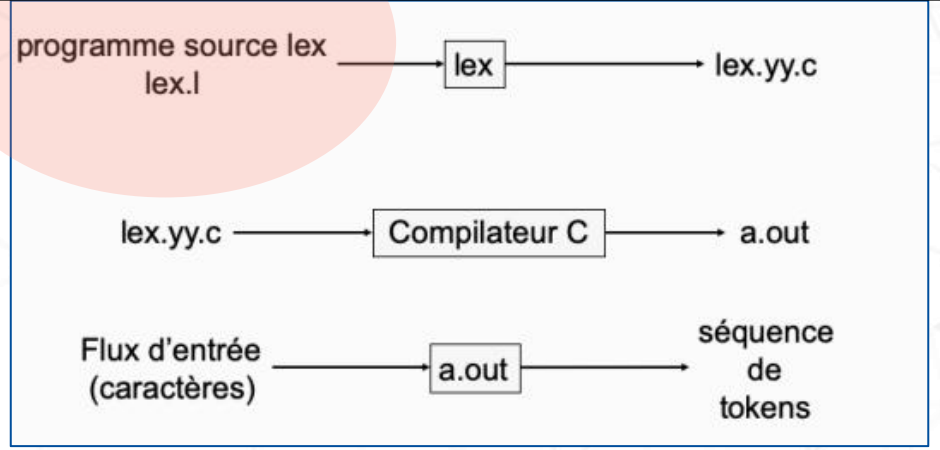

Exemple de main() classique

```
int main() {
  yylex();  // Lance l'analyse lexicale
  return 0;
}
```

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

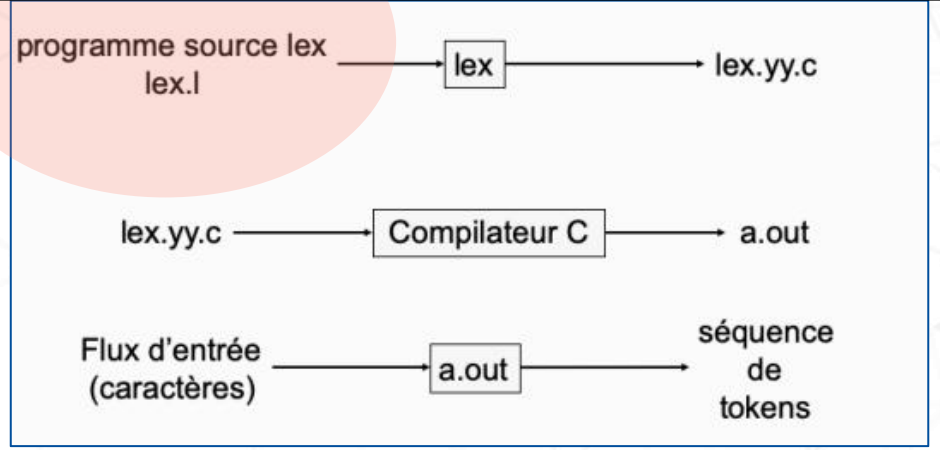

/* Code Utilisateur* /

Exemple 2: Lire depuis un fichier

```
int main(int argc, char *argv[]) {
  if (argc > 1) {
    FILE *f = fopen(argv[1], "r");
    yyin = f;  // Redirige l'entrée vers le fichier
  }
  yylex();
  return 0;
}
```

Sans fopen : L'entrée provient de stdin, donc on peut entrer du texte manuellement ou rediriger un fichier avec <.

Avec fopen : On ouvre explicitement un fichier et yyin est défini comme un fichier spécifique

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

/* Code Utilisateur* /

Exemple 3: définir des fonctions supplémentaires pour traiter des actions spécifiques

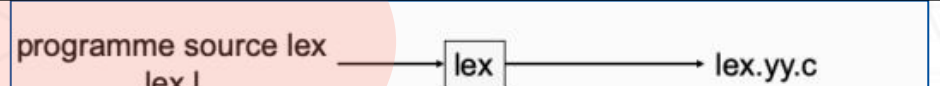


```
%{
#include <stdio.h>
#include "lex.yy.c" // Inclusion du fichier généré par Flex

// Prototype d'une fonction utilisateur supplémentaire
void message();
%}

%%
[0-9]+      { printf("Nombre détecté: %s\n", yytext); }
[a-zA-Z]+   { printf("Mot détecté: %s\n", yytext); }
.           { printf("Caractère inconnu: %s\n", yytext); }
%%

// Fonction utilisateur supplémentaire
void message() {
    printf("Analyse lexicale terminée.\n");
}

// Fonction principale (main)
int main() {
    printf("Début de l'analyse lexicale :\n");
    yylex(); // Appelle l'analyseur lexical
    message(); // Appelle la fonction utilisateur
    return 0;
}
```

L'analyse lexicale automatique: Flex

Programme source lex (Fichier .l ou .lex)

/* Code Utilisateur* /

Remarques:

- Si vous appelez **yylex()** sans configuration supplémentaire, le scanner lira depuis :Le clavier (saisie utilisateur) ou Un fichier redirigé via la ligne de commande (ex: ./a.out < input.txt).
- Si vous ne définissez pas de fonction **main()** dans votre code Flex : Flex génère une main() par défaut qui lit depuis stdin. Vous devrez alors fournir l'entrée manuellement ou via une redirection.

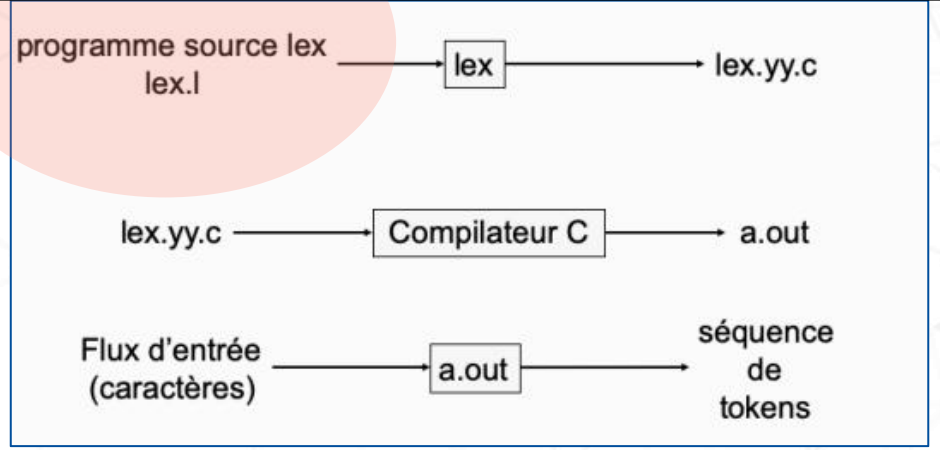

Source	Configuration Requise
Clavier (stdin)	Aucune : `yyin = stdin` par défaut.
Fichier	`yyin = fopen("fichier.txt", "r");`
Chaîne en mémoire	`yy_scan_string("ma_chaine");`
Redirection shell	`./a.out < input.txt` (automatique).

01

Analyse lexicale automatique

Compilation et exécution

L'analyse lexicale automatique: Flex

Compilation et exécution

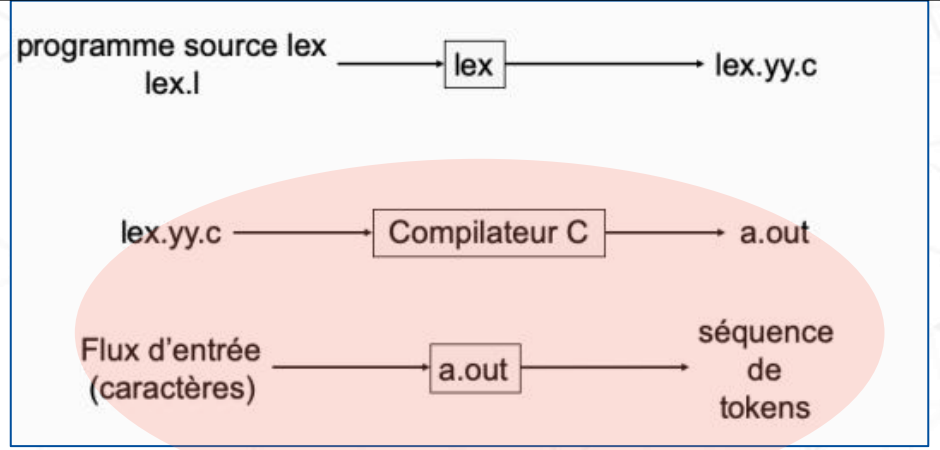

1. **Générer le lexer :**

```bash
flex exemple.l  # Produit lex.yy.c
```

2. **Compiler avec le code utilisateur :**

```bash
gcc lex.yy.c -o mon_lexer [redacted]
```

3. **Exécuter :**

```bash
./mon_lexer < input.txt
```

01

Analyse lexicale automatique

Exemple

L'analyse lexicale automatique: Flex

Exemple Complet

```
%{
#include <stdio.h>
int count = 0;
%}
%option noyywrap
%%
[a-zA-Z]+   { count++; }  // Règle pour les mots
.|\n        ;             // Ignorer les autres caractères
%%

int main() {
  yylex();
  printf("Nombre de mots : %d\n", count);
  return 0;
}
```

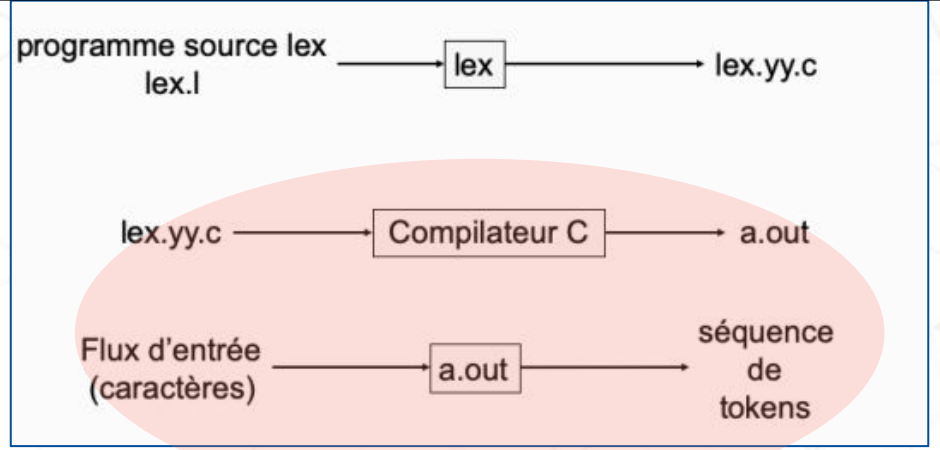

1. copier le code dans un fichier texte et enregistrer sous le nom ex1 et l'extension .l
2. générer l'analyseur en utilisant la commande:
 win_flex ex1.l
3. compiler le code de l'analyseur à l'aide de la commande:
gcc lex.yy.c -o ex1Exe.exe
4.creer un fichier texte test
5. Lancer l'analyse du fichier à l'aide de la commande:
TP1Exe < test.txt

01

Analyse lexicale automatique

Résolution de conflit

L'analyse lexicale automatique: Flex

Résolution des conflits

En cas de conflit, Flex choisit toujours la règle qui produit le plus long lexème.

Exemples

"prog" action1
"program" action2

La deuxième règle sera choisie en cas de conflit.

Si plusieurs règles donnent des lexèmes de mêmes longueurs, Flex choisit la première.

Exemples

"prog" action1
[a – z]+ action2

La première règle sera choisie en cas de conflit de lexèmes ayant mêmes longueurs

Si aucune règle ne correspond au flot d'entrée, Flex choisit sa règle par défaut implicite :

.|\n {ECHO}

Cette règle par défaut, recopie le flot d'entrée sur le flot de sortie.

01

Analyse lexicale automatique

Annexe

Annexe

Expression	Signification	Exemple
c	tout caractère *c* qui n'est pas opérateur ou métacaractère	a
\c	caractère littéral c (lorsque c est un métacaractère)	\+ \.
"s "	chaîne de caractères	"bonjour "
.	n'importe quel caractère, sauf retour à la ligne (\n)	a.b
^	l'expression qui suit ce symbole débute une ligne	^abc
$	l'expression qui précède ce symbole termine une ligne	abc$
[s]	n'importe quel caractère de s	[abc]
[^s]	n'importe quel caractère qui n'est pas dans s	[^xyz]
r*	0 ou plusieurs occurrences de r	b*
r+	1 ou plusieurs occurrences de r	a+
r?	0 ou 1 occurrence de r	d?
r{m}	m occurrences de r	e{3}
r{m,n}	entre m et n occurrences de r	f{2,4}
r_1r_2	r_1 suivie de r_2	ab
$r_1\|r_2$	r_1 ou r_2	c|d
r_1/r_2	r1 si elle est suivie de r2	ab/cd
(r)	r	(a|b)?c
<x>r	r si Lex se trouve dans l'état x	<x>abc

Annexe

Les variables yyin et yyout :

– Ce sont des variables globales de Flex de type « pointeur vers un fichier ».
– La variable yyin pointe vers le fichier d'entrée (fichier source) à analyser.
– Par défaut c'est stdin (yyin = stdin), c'est-à-dire que l'analyseur va lire les données à partir du clavier.
– On peut ouvrir un fichier source par l'instruction : « yyin = fopen(…); ».
– La variable yyout pointe vers le fichier de sortie (fichier cible).
– Par défaut c'est stdout (yyout = stdout), c'est-à-dire que l'analyseur va écrire les résultats sur l'écran.
– On peut ouvrir un fichier cible par l'instruction : « yyout = fopen(…); ».
- Une fois un lexème est reconnu, l'analyseur lexical le stocke sous forme d'une chaîne de caractères dans une variable globale appelée « yytext ».
- La longueur du lexème est également stockée sous forme d'un entier dans une variable globale appelée « yyleng » (yyleng = strlen(yytext)).
- Il est possible de contrôler la longueur maximale d'un lexème reconnu.

Annexe

- `yylex()` : c'est la fonction C de l'automate déterministe, renvoie 0 lorsque le caractère `EOF` est atteint.
- `ECHO` : afficher la chaîne reconnue
- `yytext` : chaîne de caractères reconnue
- `yyleng()` : longueur du *token*
- `yylineno()` : numéro de ligne dans le fichier où le *token* a été reconnu
- `yyin`: fichier d'entrée (`stdin` par défaut)

Merci

aida.lahouij@gmail.com